

— 이화여자대학교 컴퓨터공학과 2026-1 캡스톤디자인과 창업프로젝트B(01) · 기말발표

CLIP 기반

Zero-Shot 이미지 분류 연구

테스트 이미지의 도메인을 자동으로 파악해, 도메인 변화에 **강건한** 텍스트-이미지 임베딩 **동적 재조합**을 중심으로

1팀 이사장님		설영은(2448052) · 신지민(2466033) · 윤희서(2476199)
지도교수		황의원 교수님
트랙		연구트랙

CONTENTS

목차

01 연구의 필요성 및 목표



02 연구의 이론적 토대



03 연구 아키텍처



04 연구 방법 및 결과



05 Live Demo



06 한계와 향후 개선 방향



이사장님 소개

팀명 이사장님 | 3명의 24학번 학생들로 구성 | '24학번 모임의 장'이라는 의미



설영은

총괄 · 실험 설계 · 알고리즘 리드

- 전체 프로젝트 기획 및 일정 총괄
- 테스트 데이터셋 선정 · 수집 및 전처리
- RandomCrop, Stable Diffusion 기반 이미지 증강 구현 (총 128장)
- 결과물 최종 품질 확인 및 보고서 핵심 파트 집필



신지민

모델 구현 · 인프라 · 알고리즘 구현

- CLIP 임베딩 파이프라인 구축 및 구현
- MTA 알고리즘 설계 및 MeanShift 방법론 검토
- MeanShift 코드 구현, outlier 제거 및 mode m^* 추출
- 연구 방법론 설계 참여 및 중간 보고서 정리



윤희서

데이터 · 평가 · 프롬프트 설계

- CLIP 프롬프트 전략 수립 및 80개 템플릿 설계
- 실험 설계 및 성능 지표 측정 (분류 정확도 등)
- Ablation study 수행 및 결과 분석
- 결과 시각화 · 문헌 조사 · 보고서 자료 정리

- 연구의 필요성 및 목표

기존 CLIP의 한계

도메인 무감각

테스트 이미지가 스케치든 사진이든 동일한 평균 프롬프트로 판단

domain shift 환경에서 성능 저하



CLIP ViT-B/32

ImageNet: 63.4% → ImageNet-Sketch: 42.3% (-21.1%p)

기존 Domain Adaptation의 한계

새로운 도메인마다 추가 학습(fine-tuning)이 필요

비효율적 · 성능 향상 제한적

- 연구의 필요성 및 목표

연구 목표

01

추가 학습 없이

별도 fine-tuning 부담 제거



02

이미지 도메인을 스스로 파악

테스트 시점에 자동 추정



03

분류 기준을 자동으로 조정

도메인 가중치로 재조합



GOAL

Training-free Domain-Adaptive CLIP

- 연구의 필요성 및 목표

기존 연구와의 차별점

“ 텍스트 한쪽만 조정하던 기존 접근을 넘어, 도메인 가중치로 텍스트·이미지 양쪽을 동시에 조정하는 **Training-free Domain-Adaptive CLIP** ”

구분	기존 CLIP	TPT NeurIPS 2022	DiffTPT ICCV 2023	제안 방식 (Ours)
텍스트 임베딩	고정 평균	학습된 프롬프트	학습된 프롬프트	도메인 가중 평균 (동적)
이미지 임베딩	단순 평균	단순 평균	단순 평균	MeanShift 기반 outlier 제거
Data Augmentation	없음	RandomCrop	RandomCrop + Stable Diffusion	RandomCrop + Stable Diffusion
도메인 인식	없음	없음	없음	자동 추정 + 가중치 반영
이미지 branch	조정 없음	조정 없음	조정 없음	도메인 hint token 삽입
추가 학습	불필요	필요 (역전파)	필요 (역전파)	불필요 (training-free)

- 연구의 필요성 및 목표

타깃 사용자와 사용 시나리오



의료 AI

기기·병원마다 영상 스타일이 달라 환경에 따른 재학습 부담이 큼
→ 재학습 없이 변화에 즉시 대응, 진단 분류 정확도 유지



자율주행

날씨·시간대 변화에 지속적으로 대응해야 함
→ 실시간 Domain Shift 대응, 운행 정확도 확보



스마트팩토리

조명·카메라 교체 시마다 재학습 비용이 발생함
→ 교체 시 발생하는 재학습 비용 제거, 즉시 투입 가능



게임·콘텐츠

실사·카툰·픽셀 등 다양한 아트 스타일이 혼재함
→ 혼재된 아트 스타일 자동 분류, 라벨링 비용 절감

• 연구의 이론적 토대

CLIP (Contrastive Language-Image Pre-training)

학습 방식



대규모 이미지-텍스트 쌍으로 대조 학습.
대응되는 쌍은 임베딩 공간에서 가깝게,
아닌 쌍은 멀어지도록 학습

Zero-shot Classification

클래스 이름을 텍스트로 임베딩한 뒤,
이미지 임베딩과 코사인 유사도를 비교해
분류. 별도의 파인튜닝 불필요

Prompt Ensembling

하나의 클래스에 대해 여러 템플릿을
임베딩 후 평균 → 클래스 대표 벡터 구성



- 연구의 이론적 토대

ViT (Vision Transformer)

구조

이미지를 고정 크기 patch로 분할 후
각 patch를 token으로 변환하여
Transformer encoder로 처리

[CLS] token

전체 이미지의 전역 표현을 담는 특수 토큰.
Transformer 통과 후 최종 이미지
임베딩으로 사용

CLIP과의 관계

CLIP의 이미지 인코더가 ViT 기반. 이미지를
patch token 시퀀스로 변환해 텍스트와 같은
공간에 임베딩

Domain Shift

학습 데이터와 테스트 데이터 사이의 분포가 달라지는 현상


같은 강아지 그림이라도, (왼쪽부터 순서대로)
photo/sketch/embroidery처럼 domain이 달라지면
모델 입장에서는 전혀 다른 이미지로 인식될 수 있다.



• 연구의 이론적 토대

Test-Time Augmentation (TTA)


추론 시점에 하나의 테스트 이미지로부터 여러 augmented view를 생성해 예측 안정성을 높이는 기법.
단일 이미지만으로는 노이즈와 변형에 취약하므로, 다양한 변형 뷰의 예측을 종합하여 더 **robust**한 결과를 얻는다.



MeanShift Algorithm

데이터의 밀도를 기반으로 클러스터 중심(mode)을 반복적으로 탐색하는 알고리즘.
각 포인트를 주변 밀도가 높은 방향으로 이동시키며 수렴할 때까지 반복 → 밀도가 높은 곳이 클러스터 중심이 됨.

MTA(Meanshift algorithm for Test-time Augmentation)



- 연구 아키텍처

사전 단계

Pre-processing

- 1 도메인별 텍스트 프롬프트 구성
- 2 CLIP 기본 템플릿 확인 (27개 데이터셋 기반)
- 3 도메인 관련 템플릿 추가 및 수정
- 4 최종 프롬프트 확정 → 도메인 프롬프트 임베딩 계산

최종 확정: 17개 도메인, 총 75개 템플릿 구성
(sketch 20개 · photo 5개 · cartoon 8개 · 나머지 14개 도메인 각 3개)

27 개 데이터셋 템플릿

ImageNet	Birdsnap	CIFAR-10	CIFAR-100	CLEVRCounts
Caltech101	Country211	DTD	EuroSAT	FGVCAircraft
FER2013	Flowers102	Food101	GTSRB	HatefulMemes
KITTI	Kinetics700	MNIST	OxfordPets	PascalVOC2007
PatchCamelyon	RESISC45	SST2	STL-10	SUN397
StanfordCars	UCF101			

- 연구 아키텍처

테스트 단계

Test-Time



※ 현재 도메인 추정까지 완료된 상태로, 이후 단계는 추후 진행 예정

- 연구 방법 및 결과

데이터셋

Domain Shift 측정용 · Domain-Specific 분류용

Domain Shift 측정용

동일 클래스(ImageNet)를 다양한 도메인 변형으로 테스트하여 모델의 도메인 강건성을 측정 + PACS

ImageNet	ImageNet-A
ImageNet-V2	ImageNet-R
ImageNet-Sketch	PACS*

*PACS (Li et al., ICCV 2017)
Photo / Art painting / Cartoon / Sketch
4개 도메인, 7개 클래스 — 도메인 shift 벤치마크의 표준

Domain-Specific 분류용 (10개)

특정 도메인에 특화된 fine-grained 분류 데이터셋

SUN397 장면 분류 (397개)	Aircraft 항공기 기종 (100개)
EuroSAT 위성 이미지 토지 (10개)	StanfordCars 자동차 모델 (196개)
Food101 음식 분류 (101개)	OxfordPets 반려동물 품종 (37개)
Flower102 꽃 종류 (102개)	Caltech101 일반 객체 (101개)
DTD 질감 텍스처 (47개)	UCF101 인간 행동 (101개)

- 연구 방법 및 결과

도메인 프롬프트 구성

- 1 PACS 4개 도메인 시각적 특성 기반 프롬프트 초안 작성
- 2 각 도메인별 다수 템플릿 구성
(Photo · Art painting · Cartoon · Sketch)
- 3 CLIP 공식 ImageNet 80개 템플릿을 참고해 확장 및 보완
- 4 PACS로 추정 정확도 측정 → 성능 낮은 프롬프트 수정

최종 확정: 17개 도메인, 총 75개 템플릿 구성

(sketch 20개 · photo 5개 · cartoon 8개 · 나머지 14개 도메인 각 3개)

```
"sketch": [  
  "a black and white pencil sketch",  
  "a grayscale line drawing",  
  "a monochrome sketch",  
]
```



```
"sketch": [  
  "a black and white sketch",  
  "a grayscale sketch",  
  "a line drawing",  
  "a contour drawing",  
  "an outline drawing",  
  "a monochrome line drawing",  
  "a black and white line art image",  
  "a clean black outline drawing",  
  "a sparse black line drawing on white background",  
  "a sketch with only object contours",  
  "a white background with thin black outlines",  
  "a monochrome contour sketch",  
  "a simple object outline drawing",  
  "a line-art sketch with no shading",  
  "a black ink outline drawing",  
  "a sketch made only of edges and contours",  
  "a minimal contour-only drawing",  
  "a line art illustration",  
  "a black and white line art drawing",  
  "a minimal line-art image",  
],
```

- 연구 방법 및 결과

MTA

1

임의의 이미지 1장 선택




2

Data Augmentation RandomCrop (127장)

RandomCrop 127장

원본 1 + 증강 127 = 총 128장



- 연구 방법 및 결과

MTA

1 임의의 이미지 1장 선택



2 Data Augmentation RandomCrop (127장) · Stable Diffusion (3장)

Stable Diffusion 3장

i
Image Variation




ii
Image-to-Image

채택



iii
ControlNet



※ Stable Diffusion은 비용 제약으로 3장까지 실험, 추후 세밀하게 구현 예정

- 연구 방법 및 결과

MTA mode 평가 - 정답 라벨 0번 이미지 view 기준

정답 라벨 번호: 0
원본 view와 mode의 코사인 유사도: 0.9465

전체 view와 mode의 평균 유사도: 0.9341
전체 view와 mode의 최대 유사도: 0.9826
전체 view와 mode의 최소 유사도: 0.8470
전체 view와 mode의 유사도 표준편차: 0.0343

mode와 단순 평균 feature의 cosine similarity: 0.9918

inlierness score y의 형태: torch.Size([128])
inlierness score의 전체 합: 1.0000
가장 큰 inlierness score: 0.0275
가장 작은 inlierness score: 0.0018

1 원본 view와 mode 비교 (코사인 유사도)

mode가 원본 이미지의 의미를 잘 반영하는지 확인. 1에 가까울수록 두 임베딩 방향이 비슷합니다.

2 전체 view와 mode 비교

평균 유사도가 높고 표준편차가 작으면, 여러 augmentation 결과가 비슷한 의미를 유지한다는 뜻입니다.

3 MTA mode와 단순 평균 feature 비교

MTA 대표 임베딩이 단순 평균 feature와 얼마나 비슷한지 확인. 1에 매우 가까우면 거의 같은 방향입니다.

※ MTA ≈ 단순 평균은 "outlier 제거 후에도 방향이 유지된다"는 의미. 실제 효과는 도메인 추정 정확도로 확인 (94.64% → 97.91%)

4 inlierness score 확인

각 view가 대표 임베딩 계산 시 얼마나 신뢰할 만한지 나타내는 가중치.
softmax를 거쳐 전체 합이 1.

• 연구 방법 및 결과

도메인 추정

실험 설계

비교 대상	MTA 미적용 (원본 1장) vs MTA 적용 (원본 1장 + Augmentation 127장)
평가 지표	도메인 추정 정확도 (PACS Dataset)
실험 조건	ViT-B/32



※ 현재 도메인 추정까지 완료된 상태로, 이후 단계는 추후 진행 예정

• 라이브 데모

LIVE DEMO

Demo [Try It](#)

DEMO

도메인 추정

이미지를 업로드하면 domain을 자동 추정합니다



• RANDOMCROP x 128



• MTA - 128 VIEW EMBEDDINGS



47개 outlier 제거 → robust mode m* 획득

ESTIMATED DOMAIN

rendering

Confidence 81%

rendering	81%
graphic	7%
videogame	3%

Team Project Method Demo Next

1

이미지 업로드

Upload Image
탭해서 사진 선택

Domain Estimation 실행

2

RandomCrop 128장 증강



• RANDOMCROP x 128



※ Stable Diffusion 추후 구현 예정

outlier 제거

↓
robust mode m*

• MTA - 128 VIEW EMBEDDINGS



12개 outlier 제거 → robust mode m* 획득

3

4

도메인 추정 결과 확인

ESTIMATED DOMAIN

rendering

Confidence 86%

rendering	86%
graphic	4%
videogame	3%
toy	2%
plastic	1%

• Text embedding에 rendering weight 86% 반영됨



데모 URL

한계와 향후 개선 방향

입력 → Augmentation → 인코딩 → MTA → 도메인 추정 → 임베딩 생성 → 최종 분류

⚠ 한계

① 도메인 프롬프트 표현력 한계

- 클래스명이 포함된 프롬프트("a sketch of a cat")는 도메인과 클래스 정보가 섞여, 순수한 도메인 특성만 추정하기 어려움

② 단일 도메인 가정 vs. 가중 평균 괴리

- 실제 이미지는 대부분 하나의 도메인에 속하는데, temperature τ 가 낮으면 가중치가 특정 도메인에 쏠려 argmax와 다를 바 없어짐

③ MTA 품질에 대한 upstream 의존성

- 도메인 추정의 입력인 m^* 가 RandomCrop의 background 노이즈를 포함할 수 있어, MTA 품질 저하가 도메인 추정 오류로 이어짐

☀ 향후 개선 방향

- 여러 클래스에 걸쳐 평균낸 클래스 중립 도메인 프로토타입을 별도 구성
- Softmax Temperature τ 에 따른 도메인 가중치 분포 변화가 분류 성능에 미치는 영향 분석
- 원본 이미지로 도메인을 먼저 추정하고, 추정된 도메인 정보를 MTA에 반영함으로써 upstream 노이즈 의존성 제거 및 분류 성능 향상 기대

※ 현재 도메인 추정까지 완료된 상태로, 이후 단계는 추후 진행 예정

지도교수님 의견

1 도메인 예측 접근의 창의성

도메인을 먼저 예측한 뒤 분류하는 아이디어는 기존 연구자들이 생각하기 어려운 새로운 시각이다.

2 Feature Disentanglement 제안

CLIP 임베딩 공간에서 도메인 정보와 클래스 정보를 분리 (disentangle)하는 접근도 존재한다. 도메인 성분을 걷어내면 클래스 예측 정확도 향상을 기대할 수 있다.

3 도메인 프롬프트 학습화 제안

도메인 프롬프트 자체를 학습시키는 Prompt Tuning을 시도하는 것도 좋은 접근이다. (기존 도메인 텍스트를 초기값으로 두고 backpropagation으로 프롬프트 벡터를 업데이트)

4 벤치마크 비교 실험 필요

도메인 예측 자체는 비교 대상이 없으므로 최종 분류 성능으로 기존 TPT·DiffTPT 대비 비교가 필요해 보인다. 방학 중 연구를 완료하고 향후 좋은 컨퍼런스에 제출할 수 있기를 기대한다.

종합

지도교수님으로부터 연구 방향성과 구현 완성도에 대해 매우 긍정적인 평가를 받음.

- Resources

GitHub · 배포 URL · 참고자료



GitHub

github.com/chairwomans/chairwomans-capstone



DEMO URL

chairwomans-start-demo.hf.space

참고문헌

- Radford et al., Learning Transferable Visual Models From Natural Language Supervision, ICML 2021
- Shu et al., Test-Time Prompt Tuning for Zero-Shot Generalization in Vision-Language Models, NeurIPS 2022
- Khattak et al., MaPLe: Multi-Modal Prompt Learning, CVPR 2023
- Feng et al., Diverse Data Augmentation with Diffusions for Effective Test-time Prompt Tuning, ICCV 2023
- Zanella et al., On the Test-Time Zero-Shot Generalization of Vision-Language Models: Do We Really Need Prompt Learning?, CVPR 2024

AI 투명성 리포트

1 어떤 AI를, 어떤 작업에?

- Claude AI- 연구 아이디어 구체화, 방법론 비교 및 예시 코드 생성
- Chat GPT - 논문 속 개념 정리, 실험/코드 아이디어 보조, 면담 내용 정리
- Lilys AI - 논문 분석 및 이해, 면담 내용 정리
- Gemini - Google Colab 코드 구조 설계 보조

3 AI가 틀렸거나 못 믿었던 순간

- Claude AI가 DA 연구라고 제안했으나, 실제로는 TTA(Test-Time Adaptation)에 가까운 오류. 연구 방향 포지셔닝은 팀이 직접 판단 및 수정.
- Chat GPT가 프롬프트 은행을 직접 제작하라 했으나, CLIP 80개 템플릿이 이미 존재함을 팀이 먼저 파악 후 수정.
- Claude AI가 텍스트+비전 coupled 추론을 별도 단계로 추가했으나, 텍스트 브랜치 결과를 비전 브랜치에 넣는 구조 자체가 이미 coupled임을 팀이 먼저 파악한 오류. 구조적 중복을 스스로 인지하지 못해 팀이 직접 삭제.

2 AI 제안을 수정하거나 기각한 사례

- Claude AI - CLIP 템플릿 평균 방식을 제안
→ 도메인 가중치 기반 prompt blending 방식으로 변경
- Claude AI - 도메인 임베딩을 MLP를 통해 ViT에 삽입하는 방식을 제안
→ MLP는 추가 학습 필요, CLIP projection을 재활용하는 방식으로 수정
- Claude AI - 동일한 도메인 임베딩을 텍스트와 비전 브랜치에 함께 사용
→ 텍스트 브랜치 결과를 비전 브랜치에 coupling하는 방식으로 수정.
- Claude AI - 텍스트 임베딩을 비전 브랜치에 직접 삽입하는 방식을 제안했으나, 이후 효과가 불확실하다고 번복함. 이에 따라 효과가 있다고 가정하고 진행하기로 결정.

4 AI 없이 직접 한 것

연구 방향 설정, 연구 기획안 작성, 데이터셋 선정 검토, 실험 설계 및 최종 아이디어 도출. AI는 이해와 구현을 돕는 보조 수단으로만 활용하였으며, 연구의 방향성과 핵심 판단은 팀의 이해와 책임 하에 이루어져야 한다고 판단했기 때문.

질의응답



데모 URL