

연구트랙 | 1팀 | 지도교수: 황의원 교수님

이화여자대학교 컴퓨터공학과 2026-1 캡스톤디자인과창업프로젝트B (01)

CLIP 기반 Zero-Shot 이미지 분류 연구

테스트 이미지의 도메인을 자동으로 파악해,
도메인 변화에 강건한 텍스트-이미지 임베딩 동적 재조합을 중심으로

2026년 6월 22일

1팀 이사장님 | 설명은 (2448052) · 신지민 (2466033) · 윤희서 (2476199)

목차

1. 연구 배경 및 동기
2. 문제의 정의
3. 타겟
4. 솔루션
5. 차별성
6. 연구 아키텍처
7. 실험 내용
8. 결과 분석
9. 결론 및 향후 방향
10. 지도교수님 의견서
11. AI 투명성 리포트
12. 참고문헌

1. 연구 배경 및 동기

1.1 CLIP의 강점과 한계

CLIP(Contrastive Language-Image Pre-training)은 대규모 이미지와 텍스트의 관계를 대조 학습한 멀티모달 모델로, 별도의 파인튜닝 없이 텍스트 설명만으로 이미지를 분류하는 Zero-Shot 능력이 강점이다. Zero-Shot 분류시에는 각 클래스 이름을 다수의 자연어 프롬프트 템플릿(예: "a photo of a {class}", "a sketch of a {class}")에 삽입해 여러 텍스트 임베딩을 만든 뒤 평균하여 클래스 대표 벡터를 구성한다. 이후 이 텍스트 프로토타입과 이미지 임베딩의 코사인 유사도를 비교해 클래스를 예측한다.

그러나 이 방식은 테스트 이미지의 도메인 특성을 동적으로 반영하지 못한다는 근본적인 한계를 가진다. 예를 들어 테스트 이미지가 스케치 도메인에 속하더라도 클래스 대표 벡터는 사전 정의된 다수 템플릿의 평균값으로 고정되며, 도메인 특성이 임베딩에 반영되지 않아 이미지-텍스트 정렬 성능이 저하된다.

1.2 Domain Shift 문제

CLIP ViT-B/32를 사용하여 동일한 클래스에 대해 ImageNet과 ImageNet-Sketch에서 각각 분류 정확도를 측정하였다. 그 결과, ImageNet 63.4%에서 ImageNet-Sketch 42.3%로 21.1%p 하락하는 것을 확인하였다.

CLIP ViT-B/32 기준: ImageNet 63.4% → ImageNet-Sketch 42.3% (-21.1%p)

이처럼 학습 도메인과 테스트 도메인 사이의 분포 차이(Domain Shift)가 발생하면 분류 성능이 급격히 저하된다. 도메인 변화는 단순히 스타일 차이에 그치지 않는다. 의료 영상에서는 기기나 병원 환경마다 촬영 방식이 다르고, 자율주행 환경에서는 날씨·조도·시간대에 따라 시각적 분포가 급변하며, 스마트팩토리에서는 카메라 교체나 조명 변경이 주기적으로 발생한다. 이러한 실세계 환경에서 도메인 변화에 강건한 이미지 분류 능력은 AI 시스템의 실용성을 결정짓는 핵심 요인이다.

1.3 기존 Domain Adaptation의 한계

기존 CLIP Zero-Shot의 한계

기존 CLIP의 경우 테스트 시점에 모든 클래스에 대해 동일한 고정 평균 클래스 벡터를 사용한다. 즉, 테스트 이미지가 어떤 도메인에 속하는지 고려하지 않으며, 도메인 적응을 위한 동적 메커니즘도 존재하지 않는다.

TPT (Test-Time Prompt Tuning, NeurIPS 2022)의 한계

TPT는 테스트 이미지로부터 RandomCrop 기반의 augmented view들을 생성하고, 일관된 예측이 되도록 소프트 프롬프트를 역전파를 통해 테스트 시점에 최적화한다. 동적 프롬프트 튜닝이라는 새로운 방향을 제시했지만 두 가지 핵심 한계를 가진다.

첫째, 테스트 이미지마다 역전파 연산이 필요하여 Training-Free가 아니며 추가 연산 비용이 발생한다. 둘째, 테스트 이미지가 어떤 도메인인지를 명시적으로 추정하지 않아 entropy minimization을 통한 암묵적 적응에 그치며, 이미지 임베딩 역시 단순 평균 방식으로 처리된다.

DiffTPT (ICCV 2023)의 한계

DiffTPT는 TPT에 Stable Diffusion 기반 생성 augmentation을 결합하여 view의 다양성을 높였다. 그러나 역전파 기반 학습이 여전히 필요하고, 도메인을 명시적으로 인식하지 않아 텍스트-이미지 임베딩의 체계적인 재조합은 이루어지지 않는다.

기존 방법들은 각각 프롬프트 최적화 또는 이미지 임베딩 개선 중 한 측면만을 부분적으로 해결하며, 도메인을 스스로 파악하여 텍스트와 이미지 임베딩 양쪽을 동시에 재조합하는 Training-Free 접근은 아직 제안된 바 없다. 이것이 본 연구의 출발점이다.

2. 문제의 정의

2.1 해결하고자하는 핵심 문제

1장에서 살펴본 바와 같이, 기존 CLIP 기반 Zero-Shot 분류는 도메인 특성이 반영되지 않는 고정 임베딩, 역전파를 요구하는 기존 TTA 방법의 구조적 한계, 그리고 outlier view로 인한 이미지 임베딩 품질 저하라는 세 가지 문제를 가진다. 본 연구는 이를 다음과 같이 구체적으로 정의한다.

문제 1. 도메인 정보가 반영되지 않는 고정 임베딩

CLIP 기반 Zero-Shot 분류에서 클래스 대표 벡터가 테스트 이미지의 도메인 특성과 무관하게 고정된다. 텍스트 임베딩은 고정 평균 벡터로, 이미지 임베딩은 단순 평균으로 처리되어 Domain Shift 환경에서 이미지-텍스트 정렬이 어긋난다.

문제 2. 기존 Test-Time Adaptation의 구조적 한계

기존 Test-Time Adaptation(TTA) 방법들은 역전파를 요구하는 구조상 완전한 Training-Free 환경에서 적용이 어렵고, 텍스트 임베딩 측만 부분적으로 조정하는 데 그친다.

문제 3. Outlier View로 인한 이미지 임베딩 품질 저하

테스트 이미지로부터 생성한 여러 augmented view를 단순 평균으로 집계하면 도메인적으로 이질적인 outlier view가 최종 임베딩 품질을 저하시켜 파이프라인 전체 성능에 부정적인 영향을 준다.

2.2 핵심 질문

위 세 가지 문제로부터 다음의 핵심 연구 질문이 도출된다.

"Backpropagation 없이 테스트 시점에서 도메인을 자동으로 추정하고, 추정된 도메인 가중치를 텍스트·이미지 임베딩 양쪽에 동시에 적용하여 동적으로 재조합하면, Domain Shift 환경에서도 robust한 Zero-Shot Classification이 가능한가?"

2.3 연구 목표

본 연구의 목표는 역전파나 추가 학습 없이 테스트 시점에서만 도메인을 자동으로 추정하고, 추정된 도메인 정보를 텍스트·이미지 임베딩 양쪽에 동시에 반영함으로써 Domain Shift 환경에서도 robust한 Zero-Shot 분류 성능을 달성하는 것이다.

이를 종합한 연구 목표는 "Training-Free Domain-Adaptive CLIP", 즉 추가 학습 없이 도메인 변화에 스스로 적응하는 CLIP 기반 Zero-Shot 분류 시스템의 구현이다.

3. 타겟

3.1 주요 타겟

본 연구의 주요 타겟 대상은 Domain Shift가 발생하는 이미지를 분류해야 하지만, 매번 새로운 도메인에 대하여 파인튜닝하거나 재학습하는 것이 부담스러운 연구자 및 ML 엔지니어이다. 구체적으로는 스케치, 회화, 위성사진, 의료 이미지처럼 학습 데이터와 도메인이 다른 이미지를 다뤄야 하는 환경에서, 재학습을 위한 추가 데이터 확보나 GPU 학습 비용 없이 새로운 도메인에 즉시 대응하고자 하는 대상을 상정한다.

3.2 활용 분야별 시나리오

분야	Pain Point	본 연구 적용 시 기대 효과
의료 AI	기기·병원마다 영상 스타일이 달라 환경에 따른 재학습 부담이 큼	재학습 없이 변화에 즉시 대응, 진단 분류 정확도 유지
자율주행	날씨·조도·시간대 변화에 지속적으로 대응해야 함	날씨·조도·시간대 변화에 지속적으로 대응해야 함
스마트팩토리	조명·카메라 교체 시마다 재학습 비용이 발생함	교체 시 발생하는 재학습 비용 제거, 즉시 투입 가능
게임·콘텐츠	실사·카툰·픽셀 등 다양한 아트 스타일이 혼재함	혼재된 아트 스타일 자동 분류, 라벨링 비용 절감

4. 솔루션

4.1 핵심 아이디어

본 연구는 추가 학습 없이 테스트 시점에서만 도메인을 자동으로 추정하고 적용하는 Training-free Domain-Adaptive CLIP을 제안한다. 기존 접근들이 텍스트 임베딩만 조정하거나 역전파를 요구하는 것과 달리, 도메인 가중치를 텍스트·이미지 임베딩 양쪽에 동시에 적용하는 것이 핵심 차별점이다.

4.2 연구 기여

본 연구가 제안하는 방법론의 학문적·실용적 기여는 다음 세 가지로 요약된다.

Domain Shift 환경에서의 Zero-Shot 분류 성능 향상

도메인 가중치 기반 동적 임베딩 재조합을 통해, 기존 CLIP의 고정 평균 프롬프트 앙상블 방식 대비 Domain Shift 환경에서의 분류 정확도 개선을 목표로 한다. 특히 스케치·회화·위성사진 등 시각적 분포가 크게 다른 도메인에서도 안정적인 성능을 유지하는 것을 검증 목표로 삼는다.

Training-Free TTA 방법론 제시

역전파 없이 테스트 단계에서만 동작하므로 추가 학습 데이터나 GPU 학습 비용 없이 새로운 도메인에 즉시 적용 가능하다. 이는 데이터 확보가 어려운 의료·위성·산업용 이미지 등 특수 도메인에서 멀티모달 AI의 실용적 활용 가능성을 확대한다.

텍스트·이미지 임베딩 동시 적응 구조 설계

기존 연구들이 텍스트 임베딩만 조정하는 것과 달리, 동일한 도메인 가중치를 텍스트와 이미지 양측에 동시에 반영한다. 텍스트와 이미지가 같은 도메인 맥락을 공유하는 상태에서 비교됨으로써 이미지-텍스트 정렬 품질이 향상되는지를 실험으로 검증한다.

5. 차별점

5.1 관련 연구

CLIP (Radford et al., ICML 2021) [1]

CLIP은 4억 쌍의 이미지-텍스트 쌍을 대조 학습(Contrastive Learning)으로 사전 학습한 멀티모달 Vision-Language Model로, 별도의 파인튜닝 없이 텍스트 설명만으로 이미지를 분류하는 Zero-Shot 능력이 강점이다. 이미지와 텍스트를 동일한 임베딩 공간에 정렬하며, Zero-Shot 분류 시 클래스별 텍스트 프롬프트로 생성한 텍스트 임베딩과 이미지 임베딩 간의 코사인 유사도를 기반으로 예측을 수행한다.

TPT (Shu et al., NeurIPS 2022) [2]

TPT는 단일 테스트 이미지로부터 RandomCrop 기반 augmented view들을 생성하고, 예측의 marginal entropy를 최소화하는 방향으로 프롬프트를 테스트 시점에 역전파 기반으로 최적화한다. 이 과정에서 신뢰도가 낮은 view는 confidence selection으로 필터링된다. TPT는 테스트 시점 프롬프트 튜닝이라는 새로운 패러다임을 제시했으나, 역전파가 필수적이어서 완전한 Training-Free 환경에서는 적용이 어렵다.

MaPLe (Khattak et al., CVPR 2023) [3]

MaPLe는 few-shot 학습 데이터를 사용하여 텍스트 및 이미지 인코더 양쪽에 프롬프트를 학습하는 멀티모달 프롬프트 러닝 방법이다. 시각 프롬프트를 언어 프롬프트에 명시적으로 조건화하는 결합 함수(coupling function)를 통해 두 브랜치 간 시너지를 유도한다. 본 연구에서는 학습 기반 방법의 성능 상한(upper bound)으로 MaPLe을 참조한다.

DiffTPT (Feng et al., ICCV 2023) [4]

DiffTPT는 TPT의 구조를 계승하면서 Stable Diffusion 기반 생성 augmentation을 추가하여 augmented view의 다양성을 높인 방법이다. RandomCrop만 사용하는 TPT 대비 생성 모델을 통해 더 다양한 시각적 변형을 확보할 수 있음을 실험으로 입증한다. 다만 생성된 view의 다양성을 활용할 뿐, 테스트 샘플의 도메인을 명시적으로 추정하거나 이를 기반으로 텍스트와 이미지 임베딩을 재구성하지는 않는다. 본 연구의 RandomCrop + Stable Diffusion 조합은 이 아이디어를 참고하여 설계되었다.

MTA (Zanella et al., CVPR 2024) [5]

MTA는 "프롬프트 학습이 정말 필요한가?"라는 근본적인 질문을 제기하며, 역전파 없이 이미지 임베딩 품질 자체를 개선하는 방법을 제안한다. 다수의 augmented view 임베딩 분포에서 MeanShift 알고리즘으로 밀도 중심(mode)을 탐색하고, inlierness score 기반으로 outlier를 자동 제거하여

robust한 이미지 임베딩 m^* 를 획득한다. Gradient 계산이나 모델 파라미터 업데이트 없이 동작하는 완전한 Training-Free 구조이다. 본 연구는 MTA를 보조 기법이 아닌 전체 파이프라인의 출발점으로 통합하여, m^* 를 도메인 추정의 신뢰할 수 있는 입력으로 활용한다.

5.2 본 연구의 차별점

본 연구는 위의 선행 연구들이 각각 부분적으로 해결하고자 했던 문제들을 하나의 통합된 Training-Free 파이프라인으로 결합하여, 도메인 변화 환경에서의 CLIP 기반 Zero-Shot 분류를 개선한다.

구분	기존 CLIP	TPT (NeurIPS 2022)	DiffTPT (ICCV 2023)	MaPLe (CVPR 2023)	본 연구 (Ours)
텍스트 임베딩	고정 평균	학습된 prompt	학습된 prompt	멀티모달 사전 학습	도메인 가중 평균 (동적, Training-Free)
이미지 임베딩	단순 평균	단순 평균	단순 평균	—	MTA (MeanShift 기반 outlier 제거)
Data Augmentation	—	RandomCrop	RandomCrop + Stable Diffusion	—	RandomCrop + Stable Diffusion
도메인 인식	—	—	—	—	자동 추정 +가중치 반영
추가 학습	불필요	필요(역전파)	필요(역전파)	필요 (사전학습)	불필요 (Training-Free)

6. 연구 아키텍처

6.1 사전 단계

사전 단계에서는 도메인 추정에 사용할 텍스트 프롬프트를 구성한다. 먼저 CLIP 공식 GitHub에서 제공하는 27개 데이터셋(ImageNet, Birdsnap, CIFAR-10, CIFAR-100, CLEVRCounts, Caltech101, Country211, DTD, EuroSAT, FGVCAircraft, FER2013, Flowers102, Food101, GTSRB, HatefulMemes, KITTI, Kinetics700, MNIST, OxfordPets, PascalVOC2007, PatchCamelyon, RESISC45, SST2, STL-10, SUN397, StanfordCars, UCF101)의 템플릿을 검토하여 도메인의 시각적 특성을 반영한 템플릿을 추가 및 수정하고, 도메인 추정 정확도를 측정하여 성능이 낮은 프롬프트를 반복적으로 개선하였다.


6.2 테스트 단계

(전체 제안 파이프라인이며, 현재 구현은 ⑤ 도메인 추정까지 완료)

단계	설명
① 입력	테스트 이미지 1장 입력
② Data Augmentation	Stable Diffusion (63장) + RandomCrop (64장) + 원본 (1장) = 총 128장
③ CLIP Visual Encoder	128장 각각 CLIP 이미지 인코더로 임베딩 벡터 추출
④ MTA	MeanShift 알고리즘으로 inlier score 산출 → outlier view 자동 제거 → robust mode m^* 획득
⑤ 도메인 추정	m^* 와 도메인 프롬프트 임베딩 간 코사인 유사도 → Softmax → 도메인 가중치
⑥-A 이미지 Branch	도메인 hint token을 prefix로 삽입 후 원본 이미지 ViT 재처리 → v^* (768d) → Linear Projection (768d→512d)
⑥-B 텍스트 Branch	클래스별 템플릿을 도메인 가중치로 가중 평균 → 클래스 대표 벡터 t^* (512d)
⑦ 최종 분류	v^* 와 t^* 간 코사인 유사도 계산 → 가장 높은 유사도의 클래스를 최종 예측 레이블로 결정

6.3 주요 기술 구성 요소

CLIP (Contrastive Language-Image Pre-training)



대규모 이미지-텍스트 쌍으로 대조 학습된 멀티모달 모델로, 대응되는 쌍은 임베딩 공간에서 가깝게, 아닌 쌍은 멀어지도록 학습한다. Zero-Shot 분류 시 클래스 이름을 텍스트로 임베딩한 뒤 이미지 임베딩과 코사인 유사도를 비교해 분류하며, 별도의 파인튜닝이 불필요하다. 하나의 클래스에 대해 여러 템플릿을 임베딩 후 평균하여 클래스 대표 벡터를 구성하는 Prompt Ensembling 방식을 사용한다.

Domain Shift



학습 데이터와 텍스트 데이터 사이의 분포가 달라지는 현상이다. 예를 들어 같은 강아지 이미지더라도 도메인이 달라지면 모델 입장에서는 전혀 다른 이미지로 인식될 수 있다.

ViT (Vision Transformer)

이미지를 고정 크기 patch로 분할한 뒤, 각 patch를 token으로 변환하여 Transformer encoder로 처리한다. [CLS] token은 전체 이미지의 전역 표현을 담는 특수 토큰으로, Transformer 통과 후 최종 이미지 임베딩으로 사용된다. CLIP은 이미지 인코더가 ViT 기반이며, 이미지를 patch token 시퀀스로 변환해 텍스트와 같은 공간에 임베딩한다.

Test-Time Augmentation (TTA)

추론 시점에 하나의 테스트 이미지로부터 여러 augmented view를 생성해 예측 안정성을 높이는 기법이다. 단일 이미지만으로는 노이즈와 변형에 취약하므로, 다양한 변형 뷰의 예측을 종합하여 더 robust한 결과를 얻는다.

MeanShift Algorithm

데이터의 밀도를 기반으로 클러스터 중심(mode)을 반복적으로 탐색하는 알고리즘이다. 각 포인트를 주변 밀도가 높은 방향으로 이동시키며 수렴할 때까지 반복하여 밀도가 높은 곳을 클러스터 중심으로 삼는다.


MTA (MeanShift-based Test-Time Augmentation)

MTA는 Zanella et al. [5]에서 제안된 방법으로, N개 augmented view의 임베딩을 추출한 뒤 MeanShift로 각 view에 대한 inlierness score를 산출하고, outlier view를 자동 제거하여 robust mode m^* 를 획득하는 방법이다. 단순 평균이 outlier의 영향을 받는 문제를 해결한다.

MTA는 다음과 같은 목적 함수를 바탕으로 작동한다.[5]

$$\min_{m,y} L(m,y) = -\sum_{p=1}^N y_p K(f_p - m) - \frac{\lambda}{2} \sum_{p,q} w_{p,q} y_p y_q - \lambda_y H(y), \quad y \in \Delta^{N-1}$$

이 식의 핵심은 최종 대표 feature(m)을 찾을 때, mode에 가까우면서도 다른 신뢰도 높은 샘플들과 의미적으로 유사한 증강 view에 더 큰 가중치 y_p 를 부여한다는 점이다. 기존 MeanShift는 사실상 모든 y_p 를 동일하게 두고 feature 분포의 밀집 지점만 따라가므로, 가까이에 있는 소수의 outlier나 잘못된 증강 view의 영향을 받을 수 있다. 반면 MTA는 커널 유사도 ($K(f_p - m)$), 텍스트 기반 유사도 ($w_{p,q}$), 엔트로피 정규화 ($H(y)$)를 함께 사용하여 특정 view 하나에만 치우치지 않으면서 신뢰도 높은 증강 view들이 모인 방향으로 mode를 이동시킨다.



MTA의 inlierness score 분포와 mode 추정 과정. 출처: Zanella et al. [5], Figure 1.

그림 (a)는 mode와 가까운 점 또는 신뢰도 높은 점과 유사한 점일수록 높은 inlierness score를 받는다는 것을 보여주며, 그림 (b)는 기존 MeanShift가 흰색 화살표 방향으로 이동하는 것과 달리 MTA는 주황색 화살표처럼 높은 inlierness를 가진 밀집 영역을 향해 이동하여 고립된 outlier 영역을 피해 mode를 추정함을 나타낸다.

정리하자면, MTA는 기존 MeanShift처럼 증강된 이미지 feature들의 mode를 찾는 방법이지만, 모든 증강 view를 동일하게 사용하는 대신 각 view의 신뢰도인 inlierness score를 함께 최적화하여 더 robust한 mode m^* 를 획득할 수 있다.

7. 실험 내용

7.0 데이터셋 선정

데이터셋은 크게 두 가지 기준으로 선정하였다. 첫째, Domain Shift 측정을 위한 데이터셋으로 CLIP 원논문(Radford et al., ICML 2021)에서 Zero-Shot 평가에 활용한 ImageNet 계열 5종(ImageNet, ImageNet-A, ImageNet-V2, ImageNet-R, ImageNet-Sketch)을 사용하였다. 여기에 더하여 domain generalization 벤치마크의 표준으로 널리 활용되는 PACS를 추가하였다. PACS는 Photo, Art painting, Cartoon, Sketch의 4개 도메인과 7개 클래스로 구성되어 있으며, 도메인 레이블이 폴더 구조에 직접 인코딩되어 있어 도메인 추정 정확도 측정에 용이하다는 장점이 있다. 둘째, 특정 도메인 분류 성능 측정을 위한 데이터셋으로 "On the Test-Time Zero-Shot Generalization of Vision-Language Models: Do We Really Need Prompt Learning?"(Zanella et al., CVPR 2024)의 10-dataset 평가 프로토콜을 따라 SUN397, Aircraft, EuroSAT, StanfordCars, Food101, OxfordPets, Flower102, Caltech101, DTD, UCF101을 선정하였다.

구분	데이터셋	설명
Domain Shift 측정용	PACS (Li et al., ICCV 2017)	Domain Generalization 표준 벤치마크
	ImageNet	일반 실사 이미지 (기준)
	ImageNet-A	자연 adversarial 이미지
	ImageNet-V2	ImageNet 재수집 버전
	ImageNet-R	회화·만화·스케치 등 렌더링
	ImageNet-Sketch	순수 스케치 도메인
Domain Specific 분류용	SUN397, Aircraft, EuroSAT, StanfordCars, Food101	장면·항공기·위성·자동차·음식
	OxfordPets, Flower102, Caltech101, DTD, UCF101	반려동물·꽃·객체·질감·인간행동

7.1 도메인 프롬프트 구성

PACS 데이터셋은 도메인 레이블이 폴더 구조에 직접 인코딩되어 있어 도메인 추정 정확도 측정에 용이하다. 따라서 PACS를 이용하여 도메인 추정 정확도를 올리기 위한 프롬프트 설계를 반복 수행하였다.

절차는 다음과 같다. 첫째, PACS 4개 도메인(photo, art_painting, cartoon, sketch)의 시각적 특성을 기반으로 프롬프트 초안을 작성하였다. 각 도메인이 갖는 고유한 시각적 속성(예: sketch의 경우 흑백, 윤곽선 중심, 색채 정보 없음 등)을 기술하는 방식으로 초안을 구성하였다. 둘째, 각 도메인별 다수의 템플릿을 구성하였다. 이때 CLIP 공식 ImageNet 80개 템플릿을 참고하여 표현을 확장 및 보완하였다. 셋째, 도메인 간 모호성을 줄이기 위해 도메인별 시각적 특성을 더욱 세분화한 템플릿을 추가하는 방식으로 반복 수정하였다. 예를 들어 sketch 도메인은 "윤곽선만 존재하는 드로잉", "흰 배경에 검은 선만 있는 이미지" 등 sketch와 art_painting을 명확히 구분할 수 있는 표현으로 세분화하였다. 넷째, 도메인 간 모호성이 줄어들고 추정 정확도가 수렴할 때까지 위 과정을 반복하여 최종 템플릿을 확정하였다.

7.2 MTA - Data Augmentation

Data Augmentation은 RandomCrop은 현재 구현에 활용하고, Stable Diffusion은 후보 방식으로 비교하였다.

RandomCrop은 원본 이미지에서 임의의 영역을 잘라내어 다양한 crop view를 생성하도록 설정하였다. crop view의 개수는 파라미터 수정을 통해 조절 가능하다.

Stable Diffusion 기반 증강은 Image Variation, img2img, ControlNet(Canny) 세 가지 방식을 비교 실험하여 최적의 방식을 선택하는 방향으로 설계하였다. 각 방식에 대해 원본 이미지의 구조 보존 여부와 도메인 특성 유지 여부를 기준으로 평가하였다.

7.3 MTA 검증

MTA 검증은 획득된 mode m^* 가 원본 이미지의 의미를 잘 반영하는지, 그리고 outlier 제거가 실제로 이루어지는지를 확인하는 방식으로 설계하였다. 구체적으로 네 가지 항목을 측정하였다. 첫째, 원본 view와 mode 간 코사인 유사도를 통해 mode가 원본 이미지의 의미를 잘 반영하는지 확인하였다. 둘째, 전체 view와 mode 간 평균 유사도 및 표준편차를 통해 augmentation 결과들이 일관된 의미를 유지하는지 확인하였다. 셋째, mode와 단순 평균 feature 간 코사인 유사도를 통해 outlier 제거 후에도 임베딩 방향이 유지되는지 확인하였다. 넷째, inlier score 분포를 통해 각 view의 신뢰도 가중치가 적절히 산출되는지 확인하였다.

7.4 도메인 추정

도메인 추정 실험은 MTA 적용 여부가 도메인 추정에 미치는 영향을 측정하는 방식으로 설계하였다. 비교 대상은 MTA 미적용(원본 이미지 1장만 사용)과 MTA 적용(원본 1장 + 증강 127장, MeanShift 기반 outlier 제거)으로 설정하였다. 평가 지표는 PACS 전체 이미지에 대한 도메인 추정 정확도와 도메인별 정확도(photo, art_painting, cartoon, sketch)로 설정하였다. 백본은 CLIP ViT-B/32를 사용하였으며, 도메인 가중치 산출 시 Softmax temperature는 CLIP pretrained logit_scale.exp()를 사용하였다.

8. 결과 분석

8.1 도메인 프롬프트 구성

<pre>"sketch": ["a black and white pencil sketch", "a grayscale line drawing", "a monochrome sketch",]</pre> 보완 전	<pre>"sketch": ["a black and white sketch", "a grayscale sketch", "a line drawing", "a contour drawing", "an outline drawing", "a monochrome line drawing", "a black and white line art image", "a clean black outline drawing", "a sparse black line drawing on white background", "a sketch with only object contours", "a white background with thin black outlines", "a monochrome contour sketch", "a simple object outline drawing", "a line-art sketch with no shading", "a black ink outline drawing", "a sketch made only of edges and contours", "a minimal contour-only drawing", "a line art illustration", "a black and white line art drawing", "a minimal line-art image",],</pre> 보완 후
--	---

도메인 프롬프트 설계 과정에서 sketch 도메인의 경우 초기 3개 템플릿("a black and white pencil sketch", "a grayscale line drawing", "a monochrome sketch")으로는 art_painting 도메인과의 모호성으로 인해 추정 정확도가 낮게 나타났다. 두 도메인 모두 채색이 제한적이거나 단색 계열의 표현을 포함할 수 있어 CLIP 임베딩 공간에서 유사한 방향으로 표현되는 경향이 있었기 때문이다. 이를 해결하기 위해 sketch 고유의 시각적 특성인 윤곽선 중심 표현, 흰 배경에 검은 선만 존재하는 구조, 음영 없는 선 드로잉 등을 명시적으로 기술하는 템플릿을 반복적으로 추가하였고, 도메인 간 구분이 명확해지는 방향으로 수렴하였다.

도메인 (17개)
photo · cartoon · deviantart · embroidery · graffiti · graphic · misc · origami · sculpture · sketch · sticker · tattoo · toy · videogame · drawing · rendering · plastic

최종적으로는 17개 도메인, 총 75개 템플릿을 확정하였다. (sketch 20개 · photo 5개 · cartoon 8개 · 나머지 14개 도메인 각 3개)

8.2 MTA - Data Augmentation



RandomCrop의 경우 위 이미지와 같이 원본 이미지 1장으로부터 임의의 영역을 잘라낸 127장의 crop view를 생성하였다. crop view들은 원본 이미지의 일부 영역만을 포함하므로 객체의 특정 부위가 확대되거나 배경이 강조되는 등 다양한 시점이 확보된다. 그러나 일부 crop의 경우 객체가 거의 포함되지 않거나 배경이 과도하게 확대되는 outlier view가 발생할 수 있으며, 이러한 view를 단순 평균으로 통합하면 최종 임베딩 품질이 저하될 수 있다. 이것이 MTA를 통한 outlier 제거가 필요한 이유다.

Image Variation	 특징: 원본 이미지 스타일 변형 결과: 구조 보존 미흡
Image-to-Image	 특징: 원본 구조 유지하며 변형 결과: 채택 — 원본 구조 가장 잘 유지


ControlNet	
	특징: 엣지 기반 구조 보존 결과: 과도한 윤곽선 아티팩트 발생

Image Variation은 원본 이미지의 스타일을 변형하는 방식으로, 원본의 구조적 특성이 충분히 보존되지 않아 도메인 특성이 손상되는 문제가 발생하였다. ControlNet(Canny)은 Canny edge detection으로 추출한 엣지 맵을 조건으로 이미지를 생성하는 방식으로, 구조 보존을 의도하였으나 과도한 엣지 아티팩트가 발생하여 원본과 이질적인 결과물이 생성되었다. img2img(strength=0.3)는 원본 이미지에 noise를 가하여 변형한 뒤 denoising하는 방식으로, strength 값을 0.3으로 낮게 설정함으로써 원본의 구조적 특성과 도메인 특성을 유지하면서 색감, 질감 등 세부적인 시각적 변형만을 가할 수 있었다. 세 방식 중 원본 이미지의 도메인 특성을 가장 잘 보존하는 것으로 확인되어 최종 채택하였다.

8.3 MTA 검증

MTA 수렴 검증 결과는 다음과 같다.

평가 항목	값
원본 view ↔ mode 코사인 유사도 정답 라벨 번호: 0 원본 view와 mode의 코사인 유사도: 0.9465	0.9465
전체 view ↔ mode 평균 유사도 / 표준편차 전체 view와 mode의 평균 유사도: 0.9341 전체 view와 mode의 최대 유사도: 0.9826 전체 view와 mode의 최소 유사도: 0.8470 전체 view와 mode의 유사도 표준편차: 0.0343	0.9341 / 0.0343
mode ↔ 단순 평균 feature 코사인 유사도 mode와 단순 평균 feature의 cosine similarity: 0.9918	0.9918

원본 view와 mode 간 코사인 유사도가 0.9465로 높게 나타나, MeanShift를 통해 획득한 mode m^* 가 원본 이미지의 의미적 특성을 잘 반영하고 있음을 확인하였다. 전체 view와 mode 간 표준편차가 0.0343으로 낮게 나타난 것은 128장의 augmented view가 전반적으로 일관된 의미를 유지하고 있음을 의미한다. mode와 단순 평균 feature 간 코사인 유사도가 0.9918로 매우 높게 나타난 것은

outlier 제거 후에도 임베딩의 전체적인 방향이 유지된다는 의미이며, MTA의 실질적 효과는 단순 방향 유지가 아닌 outlier 제거를 통한 도메인 추정 정확도 향상으로 확인한다.

8.4 도메인 추정

MTA 적용 여부에 따른 도메인 추정 정확도를 비교한 결과는 다음과 같다.

조건	전체 도메인 추정 정확도	도메인별 정확도
MTA 미적용 (원본 1장)	94.64% (9454/9991) 전체 도메인 추정 정확도: 94.64% (9454/9991) 도메인별 정확도: art_painting: 93.85% (1921/2048) cartoon: 95.22% (2233/2344) photo: 92.63% (1547/1670) sketch: 96.01% (3773/3929) 예측된 도메인 분포: sketch: 3948 cartoon: 2354 art_painting: 2056 photo: 1633	- art_painting 93.85% - cartoon 95.22% - photo 92.63% - sketch 96.01%
MTA 적용 (원본 1장 + 증강 127장)	97.91% (9782/9991) 전체 도메인 추정 정확도: 97.91% (9782/9991) 도메인별 정확도: photo: 98.20% (1640/1670) art_painting: 95.95% (1965/2048) cartoon: 95.95% (2249/2344) sketch: 99.97% (3928/3929) 예측된 도메인 분포: sketch: 4019 cartoon: 2318 art_painting: 1980 photo: 1674	- photo 98.20% - art_painting 95.95% - cartoon 95.95% - sketch 99.97%

MTA 적용 시 전체 도메인 추정 정확도가 94.64%에서 97.91%로 3.27%p 향상되었다. 도메인별로 살펴보면 sketch에서 96.01%에서 99.97%로 가장 큰 폭의 개선이 나타났으며, photo 역시 92.63%에서 98.20%로 크게 향상되었다. 반면 art_painting과 cartoon은 각각 93.85%→95.95%, 95.22%→95.95%로 상대적으로 완만한 향상을 보였다. sketch와 photo에서 개선 폭이 크게 나타난 것은 두 도메인이 시각적으로 명확한 특성을 가지고 있어 MeanShift 기반 outlier 제거가 도메인 신호를 더욱 뚜렷하게 강화한 결과로 해석된다. 반면 art_painting과 cartoon은 도메인 경계가 상대적으로 모호하여 outlier 제거만으로는 개선 폭이 제한적이었던 것으로 보인다.

9. 결론 및 향후 방향

9.1 결론

본 연구는 추가 학습 없이 테스트 시점에서 도메인을 자동으로 추정하고, 추정된 도메인 가중치를 텍스트·이미지 임베딩 양쪽에 동시에 적용하는 Training-free Domain-Adaptive CLIP을 제안하였다. 현재까지 도메인 추정 단계의 구현 및 검증이 완료되었으며, 실험을 통해 다음과 같은 결론을 도출하였다.

도메인 프롬프트 설계 측면에서는 단순히 도메인 이름을 기술하는 방식으로는 도메인 간 모호성을 충분히 해소하기 어려우며, 각 도메인의 시각적 특성을 구체적으로 기술하는 템플릿을 반복적으로 구성하고 검증하는 과정이 필요함을 확인하였다. 이를 통해 최종적으로 17개 도메인, 총 75개 템플릿을 구성하였다.

Data Augmentation 측면에서는 Stable Diffusion 기반 세 가지 증강 방식 비교를 통해 `img2img(strength=0.3)`가 원본의 도메인 특성을 가장 잘 유지함을 확인하였다. 또한 RandomCrop 기반 증강에서 필연적으로 발생하는 outlier view가 단순 평균 방식의 임베딩 품질을 저하시킬 수 있음을 확인하였으며, 이는 MTA 적용의 필요성을 실험적으로 뒷받침한다.

MTA 적용 효과 측면에서는 PACS 데이터셋 기준 도메인 추정 정확도가 94.64%에서 97.91%로 3.27%p 향상되었으며, 이를 통해 MeanShift 기반 outlier 제거가 도메인 추정 품질을 실질적으로 향상시킨다는 것을 검증하였다. 특히 시각적 특성이 명확한 도메인일수록 MTA의 효과가 더 크게 나타나는 경향을 확인하였다.

이상의 결과를 종합하면, 도메인을 먼저 추정한 뒤 임베딩을 동적으로 재조합하는 접근이 Domain Shift 환경에서 유효하게 작동할 수 있음을 부분적으로 검증하였다. 향후 hint token 삽입 및 최종 분류 성능 측정을 통해 파이프라인 전체의 효과를 정량적으로 확인할 예정이다.

9.2 한계

본 연구의 실험 과정에서 다음과 같은 한계점이 발견되었다.

첫째, 도메인 프롬프트의 표현력 한계다. 본 연구에서 사용한 도메인 프롬프트는 "a sketch of a cat"과 같이 클래스명을 포함하는 형태로 구성되어 있어, 도메인 정보와 클래스 정보가 하나의 임베딩 안에 혼재된다. 이로 인해 도메인 추정 시 순수한 도메인 특성만을 반영하는 임베딩을 얻기 어려우며, 특정 클래스가 특정 도메인과 강하게 연관될 경우 도메인 추정 결과가 클래스 분포에 의해 편향될 가능성이 있다. 이를 해결하기 위한 방향으로서는 여러 클래스에 걸쳐 평균낸 클래스 중립 도메인 프로토타입을 별도로 구성하는 방법을 후속 연구에서 탐색할 예정이다.

둘째, 단일 도메인 가정과 가중 평균 방식 간의 괴리다. 실제 이미지는 대부분 하나의 도메인에 명확하게 속하는 반면, 본 연구에서는 도메인 가중치를 softmax를 통해 확률 분포로 변환하여 여러 도메인 템플릿을 가중 평균하는 방식을 사용한다. 이때 softmax temperature τ 가 낮을수록 가중치가 특정 도메인에 집중되어 사실상 argmax와 다를 바 없어지고, τ 가 높을수록 가중치가 분산되어 도메인 특성이 희석될 수 있다. 따라서 τ 값의 선택이 도메인 가중치 분포에 미치는 영향을 ablation study를 통해 분석하는 것이 필요하며, 이 역시 후속 연구 과제로 남아 있다.

셋째, 현재 파이프라인은 도메인 추정 단계까지 구현 및 검증이 완료된 상태이며, 추정된 도메인 가중치를 활용한 hint token 삽입 및 텍스트 임베딩 재조합 이후의 최종 Zero-Shot 분류 성능 측정은 방학 중 후속 연구로 진행할 예정이다. 최종 분류 성능은 TPT, DiffTPT 등 기존 방법과의 정량 비교를 통해 본 연구의 차별성을 수치로 검증하는 방향으로 진행할 계획이다.

9.3 향후 개선 방향

향후 연구 방향은 자체 계획과 지도교수 권고 사항을 중심으로 다음과 같이 설정하였다.

우선 현재 도메인 추정 단계까지 완료된 파이프라인을 확장하여 hint token 삽입 및 텍스트 임베딩 재조합을 포함한 전체 파이프라인의 Zero-Shot 분류 정확도를 측정할 예정이다. 이후 동일 데이터셋에서 TPT, DiffTPT 등 기존 방법과의 정량 비교 실험을 수행하여 본 연구의 차별성을 수치로 검증한다.

방법론적 개선 방향으로는 세 가지를 탐색할 예정이다. 첫째, 현재 도메인 프롬프트의 표현력 한계를 해결하기 위해 여러 클래스에 걸쳐 평균낸 클래스 중립 도메인 프로토타입을 별도로 구성하는 방향을 검토한다. 둘째, Softmax temperature τ 값 변화에 따른 도메인 가중치 분포와 분류 성능의 관계를 ablation study를 통해 분석한다. 셋째, CLIP 임베딩 공간에서 도메인 정보와 클래스 정보를 분리하는 Feature Disentanglement 방향을 탐색한다.

또한 도메인 프롬프트 자체를 학습시키는 Prompt Tuning 방식도 도입을 검토한다. CoOp과 유사하게 기존 도메인 텍스트를 초기값으로 두고 backpropagation으로 프롬프트 벡터를 업데이트하는 방식으로, 오프라인 사전학습 형태로 도입함으로써 테스트 시점의 training-free 조건은 그대로 유지한다. 이상의 연구를 방학 중 완료하여 컨퍼런스 제출을 목표로 한다.

10. 지도교수님 의견서

교 과 목: 2026-1 캡스톤디자인과창업프로젝트B (01)

팀 명: 1팀 이사장님

팀 원: 설영은(2448052), 신지민(2466033), 윤희서(2476199)

연 구 제 목: 테스트 이미지의 도메인을 자동으로 파악해 텍스트와 이미지 임베딩을 동적으로
재조합함으로써 도메인 변화에도 정확한 CLIP 기반 Zero-Shot 이미지 분류 연구

면 담 일: 2026년 6월 4일 (목) 18:30

지 도 교 수: 황의원 (이화여자대학교 컴퓨터공학과)

1. 연구 개요 및 진행 상황 평가

본 팀은 CLIP 임베딩 공간에서 도메인 추정을 선행한 뒤, 그 결과를 바탕으로 텍스트 및 이미지 임베딩을 동적으로 조정하여 최종 분류를 수행하는 독창적인 파이프라인을 제안하였습니다. 기존 TPT, DiffTPT 등 프롬프트 학습 기반 방법과 달리, 추가 학습 없이 도메인 가중 평균 임베딩을 활용한다는 점에서 차별성이 명확하다고 판단됩니다.

현재 도메인 프롬프트 구성(17개 도메인, 최종 75개 템플릿), MTA(Mean-Shift 기반 이상치 제거) 구현, PACS 데이터셋 기반 도메인 추정 실험(MTA 적용 후 약 3.27%p 정확도 향상, 전체 도메인 추정 정확도 97.91%)까지 완료한 상태이며, 데모 시연 환경도 갖추고 있어 연구 방향성과 구현 완성도에 대해서도 매우 우수한 수준으로 보입니다.

2. 주요 기술적 의견

2-1. 도메인 추정

도메인을 사전에 추정하여 분류에 반영하는 접근은 성능 향상 측면에서 효과적일 것으로 보이지만, 사전에 정의된 도메인 풀에 한정된다는 구조적인 한계도 존재할 수 있습니다. 예를 들어, 스케치 이미지에서 비디오 프레임으로 전환되는 것과 같이 입력 도메인이 극단적으로 변하는 상황을 가정할 경우, 도메인 추정이 매 인스턴스마다 정확하게 전환되어야 하는데, 현재 정해진 프롬프트로 도메인 추정을 하는 방식을 유지한다면 이러한 급격한 도메인 시프트 상황에서도 안정적으로 동작할 수 있는지에 대한 고민이 필요해 보입니다.

2-2. 도메인과 클래스 임베딩의 분리(Disentanglement)

CLIP 임베딩 공간에서는 도메인 정보와 클래스 정보가 혼재되어있어, 도메인을 맞추려는 과정에서 클래스 정보가 영향을 받고 반대로 클래스를 맞추려는 과정에서 도메인 정보가 영향을 주어 분류

정확도를 떨어뜨릴 수 있습니다. 이를 해결하여 도메인의 영향을 받지 않고 클래스 분류를 정확하게 하는 것이 도메인 적응(Domain Adaptation)의 목표입니다. 위 연구에서도 이러한 한계점이 존재하기 때문에, CLIP 임베딩 공간에서 서로 얽혀있는 도메인과 클래스 정보를 풀어내는 방법인 Feature Disentanglement를 고려해볼 수 있습니다. 예를 들어 임베딩이 256차원이라면, 이 중 128차원은 도메인 특성을, 나머지는 클래스 특성을 담당하도록 분리하고, Adversarial 학습(도메인 분류기와 인코더를 경쟁 학습)을 통해 도메인 정보가 해당 차원 쪽으로 쏠리도록 유도한 뒤 그 차원을 제거하면, 남은 차원에는 도메인 영향을 받지 않은 클래스 정보가 남아 분류 정확도 향상을 기대할 수 있습니다. 본 팀의 접근 방식은 별도의 분류기 학습이 불필요하다는 장점이 있으나, 도메인 프롬프트로 사전 정의된 도메인 풀 밖의 새로운 도메인에는 취약할 수 있다는 트레이드오프가 존재함을 유의해야 합니다.

2-3. 도메인 프롬프트 학습(Prompt Tuning) 확장 제안

팀이 제안한 '도메인 프롬프트 자체를 학습으로 생성'하는 아이디어는 독창적인 방향으로 보입니다. 이는 일반적으로 Prompt Tuning이라고 불리는 접근으로, 탐색 후보가 방대한 프롬프트 공간을 효율적으로 다루기 위해 기존 수작업 프롬프트를 초기값으로 설정한 뒤 역전파를 통해 프롬프트 벡터를 직접 업데이트하는 방식입니다. 이는 새로운 도메인에 대한 일반화 성능을 높이는 동시에 본 연구의 독창성을 강화하는 방향이 될 수 있으므로 방학 중 이를 시도해보는 것을 적극 권장합니다.

2-4. 비교 실험 설계에 대한 권고

도메인 예측 자체는 기존에 이를 독립적인 연구 과제로 다룬 선행 연구가 거의 없어 직접적인 비교 대상 방법론이 매우 제한적입니다. 이는 본 연구가 새롭게 제안한 접근인 만큼 불가피한 측면이 있으나, 최종적으로는 클래스 분류 성능으로 귀결되므로 이 부분에서는 정량적인 비교가 충분히 가능합니다. 따라서 기존 TPT 및 Diffusion-TPT 대비 본 연구의 성능 수치를 명확히 제시하여 성능 우위를 입증하는 것이 필수적입니다. 방학 중 표준 벤치마크(ImageNet 계열 5종, PACS 등 도메인 시프트 데이터셋 10종)에서 비교 실험을 수행하고, 기존 대비 성능 개선을 수치로 제시할 수 있도록 준비해야 합니다. 아울러 기존 연구 대비 차별점을 표 등으로 미리 정리해두면 보고서 및 추후 논문 작성 시 한결 수월할 것으로 보입니다.

2-5. 기존 아이디어의 재조합과 연구의 독창성에 대한 조언

본 연구가 기존에 존재하던 여러 방법론(MTA, Test-Time Augmentation, Test-Time Prompt Tuning 등)을 조합하여 구성된 것에 대한 우려가 있을 수 있지만, 창의성이란 완전히 새로운 것을 무에서 창조하는 것이 아니라 기존에 존재하던 요소들을 새로운 방식으로 조합하여 의미 있는 차이를 만들어내는 데에서 비롯됩니다. 다만 동일한 분야에서 이미 시도된 아이디어를 그대로 차용하는 경우에는 독창성을 인정받기 어려운 반면, 다른 분야에서 사용되던 기법을 새로운 문제에 적용하여 효과를 입증하는 경우는 분명한 창의성과 새로움으로 인정받을 수 있습니다. 기존에 많은 연구자들이 유사한 방식으로 연구를 수행하고 있다는 점을 참고하시면 좋을 것 같습니다.

3. 발표 시 유의사항

발표 초반에 '도메인 적응이란, 도메인이 서로 다른 상황에서 동일한 클래스를 정확히 예측하는 것'이라는 정의를 명확히 제시할 것을 권장합니다. 도메인과 클래스 개념이 혼동될 수 있으므로, 이를 먼저 정립하면 청중의 이해도를 높이는 데 효과적일 것이라 조언하였습니다.

4. 종합 의견

본 팀의 연구는 분류 이전 단계에서 도메인 추정을 선행하는 창의적 발상을 바탕으로 하고 있으며, TPT 계열 연구의 오랜 난제였던 증강 방식의 한계를 다각도로 분석하여, 해당 분야에서 쉽게 떠올리지 못하는 독창적인 시각을 제시했다고 생각합니다. 특히 기존 연구들은 다양한 augmented view를 확보하는 과정에 어려움을 겪어왔으며, 단순한 Randomcrop이나 Rotation 변형을 넘어 DiffTPT처럼 Stable Diffusion을 활용한 사례도 존재합니다. 자율주행처럼 날씨나 조도 변화에 실시간으로 대응해야 하는 분야에서는 Stable Diffusion의 느린 처리 속도가 치명적인 제약이 될 수 있습니다. 그러나 의료 진단과 같이 실시간성보다 정확도가 명확히 우선되는 영역에서는 다소 시간이 소요되더라도 고성능 모델을 활용하는 방식이 훨씬 유리합니다. 따라서 현재 고수하고 계신 연구 방향을 그대로 유지하며 발전시켜 나가시기를 권장합니다.

또한 모든 도메인에서 일반적으로 우수한 성능을 보이지 않더라도, 특정 상황이나 도메인에서 확실한 성능 향상을 보이는 것만으로도 캡스톤 디자인과 창업 프로젝트에 적합한 결과로 평가될 수 있습니다. 다른 분야의 아이디어를 차용하여 새로운 문제에 적용하는 것이 창의적 연구의 본질이라는 점을 팀원들이 잘 인식하고 있다고 생각하며, 이는 향후 좋은 성과로 이어질 가능성이 충분합니다. 방학 중 비교 실험을 완료하고 Prompt Tuning을 시도하며 실험 성능을 최적화한다면, 완성도 높은 연구 결과를 도출할 수 있을 것으로 기대하는 바입니다.

11. AI 투명성 리포트

11.1 AI 활용 현황

본 연구는 작업 성격에 따라 적합한 AI 도구를 구분하여 보조적으로 활용하였다.

- Claude AI: 연구 아이디어 구체화, 방법론 비교 및 예시 코드 생성
- ChatGPT: 논문 속 개념 정리, 실험·코드 아이디어 보조, 면담 내용 정리
- Lilys AI: 논문 분석 및 이해, 면담 내용 정리
- Gemini: Google Colab 코드 구조 설계 보조

11.2 AI 제안 수정·기각 사례

AI가 제시한 제안 가운데 기술적으로 비효율적이거나 부적절한 부분은 팀의 검토를 거쳐 수정하거나 기각하였다. Claude AI는 초기에 CLIP 템플릿을 단순 평균하는 방식을 제안하였으나 도메인 가중치 기반의 prompt blending 방식으로 변경하였고, 도메인 임베딩을 MLP를 통해 ViT에 삽입하는 방식을 제안받았으나 추가 학습이 필요하다는 점에서 CLIP의 기존 projection을 재활용하는 방식으로 수정하였다. 텍스트 임베딩을 비전 브랜치에 직접 삽입하는 방식을 제안한 뒤 스스로 반복한 사례도 있었는데, 팀은 효과가 있다고 가정하고 진행하기로 자체적으로 판단하였다.

11.3 인간 주도 핵심 연구 영역

AI는 연구 내용을 이해하고 구현하는 과정을 돕는 보조적 수단으로만 활용하였으며, 연구의 방향성과 핵심적인 판단은 팀의 이해와 책임 아래 이루어져야 한다고 판단하였다. 따라서 연구 방향 설정, 연구 기획안 작성, 데이터셋 선정 검토, 실험 설계 및 최종 아이디어 도출은 AI의 개입 없이 팀이 전적으로 수행하였다.

11.4 AI 한계 인식 및 대응

AI의 제안 가운데 사실과 다르거나 신뢰하기 어려운 부분은 팀이 직접 검증하고 수정하였다. Claude AI는 본 연구를 DA 연구로 분류하였으나, 실제로는 TTA에 더 가까운 오류로 판단되어 팀이 직접 연구의 포지셔닝을 수정하였다. ChatGPT는 프롬프트 은행을 새로 제작할 것을 제안하였으나, CLIP 공식 80개 템플릿이 이미 존재한다는 사실을 팀이 먼저 파악하여 불필요한 작업을 방지하였다. 또한 Claude AI는 텍스트와 비전의 coupled 추론을 별도의 단계로 추가할 것을 제안하였으나, 텍스트 브랜치의 결과를 비전 브랜치에 반영하는 구조 자체가 이미 coupled 구조임을 팀이 먼저 인지하여 구조적 중복을 직접 삭제하였다.

12. 참고문헌

- [1] Radford et al., Learning Transferable Visual Models From Natural Language Supervision, ICML 2021
- [2] Shu et al., Test-Time Prompt Tuning for Zero-Shot Generalization in Vision-Language Models, NeurIPS 2022
- [3] Khattak et al., MaPLe: Multi-Modal Prompt Learning, CVPR 2023
- [4] Feng et al., Diverse Data Augmentation with Diffusions for Effective Test-time Prompt Tuning, ICCV 2023
- [5] Zanella et al., On the Test-Time Zero-Shot Generalization of Vision-Language Models: Do We Really Need Prompt Learning?, CVPR 2024

GitHub | <https://github.com/chairwomans/chairwomans-capstone>

Demo | <https://chairwomans-start-demo.hf.space>